

**LAPORAN AKHIR PROJECT MACHINE LEARNING
KLASIFIKASI KATEGORI GAJI PEKERJA PADA DATA TIDAK SEIMBANG
MENGUNAKAN RANDOM FOREST DENGAN PENDEKATAN CLASS
WEIGHTING UNTUK MENINGKATKAN AKURASI PREDIKSI
KELOMPOK BERPENDAPATAN TINGGI**

UNTUK MEMENUHI UJIAN AKHIR SEMESTER
MATA KULIAH PEMBELAJARAN MESIN



Oleh :

KAYLA VERDA FAWNIA HESES

A11.2024.15689

A11.4404

PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO SEMARANG

2026

DAFTAR ISI

PETA PEMENUHAN SOAL UJIAN AKHIR SEMESTER.....	3
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang Masalah.....	4
1.2 Tujuan Bisnis dan Analisis.....	4
1.3 Metrik Kesuksesan Proyek.....	5
1.4 Sumber dan Identitas Dataset.....	5
1.5 Statistik Deskriptif Awal.....	5
BAB II PERUMUSAN MASALAH	7
2.1 Identifikasi Masalah.....	7
2.2 Rumusan Masalah.....	7
2.3 Tujuan Proyek.....	8
2.4 Definisi Learning Task.....	8
2.5 Hipotesis Awal.....	9
BAB III ANALISIS DATASET & REPRESENTASI DATA.....	11
3.1 Sumber dan Identitas Dataset	11
3.2 Struktur Data dan Tipe Fitur	11
3.3 Tabel Deskripsi Fitur	11
3.4 Analisis Representasi Data.....	12
3.5 Identifikasi Tantangan Dataset.....	14
BAB IV PERANCANGAN PIPELINE.....	16
4.1 Data Preprocessing.....	16
4.2 Feature Engineering	18
4.3 Data Splitting Strategy	18
4.4 Pipeline Workflow End-to-End.....	18
BAB V STRATEGI PEMODELAN & EKSPERIMEN	20
5.1 Algoritma Machine Learning yang Dipilih.....	20
5.2 Rancangan Eksperimen.....	21
5.3 Metrik Evaluasi.....	22
5.4 Hasil Eksperimen: Perbandingan 5 Model	22
5.5 Validasi dan Diagnosis Model	25
5.6 Interpretasi Model.....	26
5.7 Pemilihan Model Terbaik dan Justifikasi	28
BAB VI DEPLOYMENT MODEL.....	30
6.1 Bentuk Deployment	30
6.2 Model yang Digunakan.....	30
6.3 Alur Input → Model → Output.....	31
6.4 Diagram Alur Inference	32
6.5 Struktur File Sistem	32
6.6 Arsitektur Sistem	33
BAB VII DEPLOYMENT APLIKASI STREAMLIT	34
7.1 Ringkasan Aplikasi	34
7.2 Tab 1: Dashboard EDA.....	34
7.3 Tab 2: Model Demo	35
7.4 Tab 3: Evaluasi Model	35
7.5 Tab 4: Interpretasi Hasil.....	37
7.6 Tab 5: Dokumentasi	38
BAB VIII KESIMPULAN DAN REKOMENDASI.....	39
8.1 Kesimpulan	39
8.2 Rekomendasi.....	39
DAFTAR PUSTAKA.....	41

PETA PEMENUHAN SOAL UJIAN AKHIR SEMESTER

Tabel berikut menunjukkan bagian-bagian dari laporan ini yang menjawab masing-masing soal pada lembar Ujian Akhir Semester mata kuliah Pembelajaran Mesin untuk memudahkan proses pemeriksaan.

Soal	Topik	Lokasi pada Laporan
Soal 1	Problem Definition & Data Acquisition	BAB I Pendahuluan
Soal 2	Exploratory Data Analysis & Preprocessing	BAB III Analisis Dataset & Representasi Data, BAB IV Perancangan Pipeline
Soal 3	Modeling & Evaluation	BAB II Perumusan Masalah (2.4), BAB V Strategi Pemodelan & Eksperimen
Soal 4	Deployment & Streamlit Application	BAB VI Rencana Deployment Model & BAB VII Deployment Aplikasi Streamlit
Soal 5	Documentation & Presentation	Keseluruhan laporan ini

BAB I PENDAHULUAN

1.1 Latar Belakang Masalah

Ketimpangan pendapatan adalah isu yang selalu relevan untuk dibahas, baik dari sisi kebijakan publik maupun dari sisi bisnis seperti perencanaan tunjangan karyawan, penentuan segmentasi produk keuangan, atau program pengembangan sumber daya manusia. Ini bukan sekadar isu teoretis, data resmi Badan Pusat Statistik yang dirilis Februari 2026 mencatat Gini Ratio Indonesia masih berada di angka 0,363 pada September 2025, menunjukkan bahwa kesenjangan pendapatan masih jadi kondisi nyata yang perlu terus dipahami polanya.

Sistem kompensasi yang tidak didasarkan pada data cenderung menimbulkan ketimpangan, misalnya pekerja dengan latar belakang pendidikan dan jam kerja yang setara justru menerima kategori pendapatan yang berbeda hanya karena faktor subjektif. Salah satu cara memahami pola di balik ketimpangan ini adalah dengan membangun model klasifikasi yang mampu memprediksi apakah seseorang termasuk kelompok berpendapatan tinggi atau tidak, berdasarkan atribut demografis dan pekerjaan yang dimilikinya.

Permasalahan yang diangkat pada proyek ini adalah klasifikasi biner kategori gaji pekerja (kurang dari sama dengan tujuh juta rupiah dan lebih dari tujuh juta rupiah) menggunakan fitur seperti umur, tingkat pendidikan, status perkawinan, jenis pekerjaan, jam kerja per minggu, serta keuntungan dan kerugian kapital yang dimiliki. Tantangan utamanya adalah ketidakseimbangan kelas, hanya sekitar 24 persen data yang masuk kelompok berpendapatan tinggi, sehingga model yang dibangun tanpa penanganan khusus cenderung bias memprediksi kelas mayoritas dan gagal mengenali kelompok berpendapatan tinggi yang justru menjadi fokus analisis proyek ini.

1.2 Tujuan Bisnis dan Analisis

Dari sudut pandang bisnis, model semacam ini dapat dimanfaatkan misalnya oleh divisi HR atau lembaga keuangan untuk melakukan skrining awal terhadap kelompok berpendapatan tinggi tanpa harus menunggu data slip gaji resmi yang sifatnya sensitif dan sulit diakses secara masif. Dari sudut pandang analisis, tujuan utama proyek ini adalah membangun model klasifikasi yang tidak hanya akurat secara keseluruhan, tetapi tetap sensitif terhadap kelas

minoritas berpendapatan tinggi, mengingat kelas inilah yang paling bernilai untuk diidentifikasi namun paling rawan diabaikan oleh model standar pada data tidak seimbang.

1.3 Metrik Kesuksesan Proyek

Karena fokus utama proyek ini ada pada kelas minoritas, metrik akurasi saja tidak cukup untuk menilai keberhasilan model. Metrik kesuksesan yang dipakai pada proyek ini adalah sebagai berikut.

- Recall kelas berpendapatan tinggi ($>7jt$), karena kegagalan mendeteksi kelompok ini (false negative) dianggap lebih merugikan dibanding kesalahan sebaliknya.
- F1-score kelas $>7jt$, sebagai penyeimbang antara recall dan precision agar model tidak asal menebak positif demi mengejar recall tinggi.
- ROC-AUC, untuk menilai kemampuan model membedakan kedua kelas secara keseluruhan tanpa bergantung pada satu ambang batas tertentu.
- Target minimal yang ditetapkan pada proyek ini adalah recall kelas $>7jt$ di atas 0,75 dan ROC-AUC di atas 0,85. Target ini telah tercapai oleh seluruh model yang menerapkan penanganan class imbalance, sebagaimana dibahas pada BAB V.

1.4 Sumber dan Identitas Dataset

Dataset yang dipakai bersumber dari Kaggle dengan judul "Final Project Sanbercode 0720", merupakan varian dari UCI Adult Census Income Dataset (Kohavi, 1996) yang telah diterjemahkan ke Bahasa Indonesia dan disesuaikan nilai gajinya dalam satuan rupiah. Proses pengunduhan dapat dilakukan secara terprogram menggunakan pustaka kagglehub, dengan berkas train.csv lokal disiapkan sebagai cadangan apabila autentikasi Kaggle tidak tersedia di environment yang dipakai.

Tautan dataset: <https://www.kaggle.com/datasets/anasimron/final-project-sanbercode-0720>

1.5 Statistik Deskriptif Awal

Sebelum pembersihan, dataset mentah berukuran 35.994 baris dan 13 kolom, terdiri dari 5 kolom numerik (Umur, Jmlh Tahun Pendidikan, Keuntungan Kapital, Kerugian Capital, Jam per Minggu), 6 kolom kategorikal bertipe teks (Kelas Pekerja, Pendidikan, Status Perkawinan, Pekerjaan, Jenis Kelamin, Gaji), ditambah kolom id dan Berat Akhir yang nantinya dibuang karena tidak relevan untuk pemodelan.

Atribut	Detail
Jumlah Baris (mentah)	35.994 baris data pekerja
Jumlah Kolom	13 kolom (12 fitur input + 1 target)
Nilai Hilang	2.063 baris pada Kelas Pekerja (5,73%) dan 2.069 baris pada Pekerjaan (5,75%), disimbolkan tanda tanya
Distribusi Target	27.364 baris (76,02%) kategori ≤ 7 jt, 8.630 baris (23,98%) kategori > 7 jt, rasio imbalance 3,17 : 1
Struktur Dataset	Varian dari UCI Adult Census Income Dataset (Kohavi, 1996)

Detail lebih lanjut mengenai tipe data dan statistik tiap kolom, termasuk hasil setelah tahap pembersihan data, disajikan pada BAB III dan BAB IV.

BAB II PERUMUSAN MASALAH

2.1 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan pada bab sebelumnya, terdapat beberapa permasalahan utama yang menjadi dasar pelaksanaan proyek ini.

- Distribusi kelas pada variabel target Gaji bersifat tidak seimbang, dengan proporsi 76,02 persen untuk kategori kurang dari sama dengan tujuh juta rupiah dan 23,98 persen untuk kategori lebih dari tujuh juta rupiah, sehingga berisiko menghasilkan model yang bias terhadap kelas mayoritas apabila dilatih tanpa penanganan khusus.
- Belum diketahui secara empiris seberapa besar pengaruh penerapan pendekatan class weighting terhadap kemampuan model dalam mengenali kelompok berpendapatan tinggi yang merupakan kelas minoritas dalam dataset.
- Belum diketahui apakah Random Forest benar-benar merupakan pilihan algoritma terbaik untuk kasus ini, sehingga diperlukan perbandingan dengan algoritma dari keluarga yang berbeda, yaitu model linear dan model gradient boosting.
- Belum teridentifikasi secara terstruktur atribut demografis dan latar belakang pekerjaan mana yang paling dominan memengaruhi kategori gaji seorang pekerja, padahal informasi ini penting sebagai dasar analisis kesenjangan ekonomi.
- Beberapa kolom pada dataset, seperti Kelas Pekerja dan Pekerjaan, mengandung nilai hilang yang disimbolkan dengan tanda tanya, sehingga memerlukan strategi preprocessing yang tepat agar tidak menurunkan kualitas model.

2.2 Rumusan Masalah

Berdasarkan identifikasi masalah tersebut, rumusan masalah dalam proyek ini disusun ke dalam empat poin utama.

- Bagaimana pengaruh ketidakseimbangan distribusi kelas pada variabel Gaji terhadap performa model klasifikasi Random Forest apabila dilatih tanpa penanganan khusus, khususnya pada metrik recall dan F1-score kelas minoritas?
- Seberapa efektif pendekatan class weighting pada algoritma Random Forest dalam meningkatkan kemampuan model mengenali kelompok pekerja berpendapatan tinggi, dibandingkan dengan model Random Forest standar tanpa penanganan imbalance?

- Apakah Random Forest tetap menjadi pilihan terbaik apabila dibandingkan dengan algoritma dari keluarga berbeda, yaitu Logistic Regression (linear) dan XGBoost (gradient boosting), yang menerapkan mekanisme penanganan imbalance yang setara?
- Fitur atau atribut apa saja yang memiliki tingkat kepentingan (feature importance) paling tinggi dalam menentukan kategori gaji pekerja, dan apakah kesimpulan tersebut konsisten di berbagai teknik interpretasi model yang berbeda prinsip kerja?

2.3 Tujuan Proyek

- Membangun model klasifikasi biner menggunakan algoritma Random Forest untuk memprediksi kategori gaji pekerja berdasarkan atribut demografis dan latar belakang pekerjaan.
- Menerapkan dan mengevaluasi pendekatan class weighting untuk mengatasi ketidakseimbangan distribusi kelas pada variabel target Gaji.
- Membandingkan performa Random Forest dengan class weighting terhadap Random Forest standar, Logistic Regression, dan XGBoost menggunakan metrik akurasi, precision, recall, F1-score, dan ROC-AUC.
- Mengidentifikasi fitur-fitur yang paling signifikan dalam menentukan kategori gaji pekerja melalui tiga teknik interpretasi yang saling melengkapi, yaitu feature importance bawaan, permutation importance, dan SHAP.
- Mengembangkan dan men-deploy aplikasi web interaktif berbasis Streamlit yang memungkinkan pengguna non-teknis melakukan eksplorasi data, mencoba prediksi model, meninjau evaluasi, dan memahami interpretasi hasil.

2.4 Definisi Learning Task

Jenis learning task yang digunakan dalam proyek ini adalah Supervised Learning dengan tugas Klasifikasi Biner. Model dilatih menggunakan data pekerja yang telah memiliki label kategori gaji aktual, dan karena output yang diprediksi berbentuk kategori diskret, maka tugas ini secara definitif termasuk klasifikasi, bukan regresi.

Komponen	Definisi
Jenis Task	Supervised Learning - Klasifikasi Biner
Target / Label Variable	Gaji (dikonversi ke numerik: 0 = <=7jt, 1 = >7jt)

Komponen	Definisi
Input Features	Umur, Kelas Pekerja, Pendidikan, Jmlh Tahun Pendidikan, Status Perkawinan, Pekerjaan, Jenis Kelamin, Keuntungan Kapital, Kerugian Capital, Jam per Minggu
Algoritma Utama	Random Forest dengan Class Weighting dan tuning RandomizedSearchCV (model utama untuk deployment)
Algoritma Pembanding	Random Forest Baseline dan Random Forest + Class Weighting tanpa tuning (variasi internal), Logistic Regression dengan Class Weighting (keluarga linear), serta XGBoost dengan scale_pos_weight (keluarga gradient boosting)
Teknik Interpretasi	Feature importance bawaan Random Forest, Permutation Importance, dan SHAP (TreeExplainer)

2.5 Hipotesis Awal

“Model Random Forest dengan pendekatan class weighting akan menghasilkan nilai recall dan F1-score pada kelas minoritas ($>7\%$) yang secara signifikan lebih tinggi dibandingkan model Random Forest standar, karena mekanisme pembobotan kelas memaksa algoritma memberi penalti lebih besar terhadap kesalahan klasifikasi pada kelas minoritas selama proses pembentukan pohon keputusan. Random Forest juga diperkirakan akan mengungguli Logistic Regression karena kemampuannya menangkap interaksi non-linear antar fitur, meskipun XGBoost sebagai sesama model berbasis pohon berpotensi memberikan performa yang sebanding atau lebih baik. Selain itu, fitur Keuntungan Kapital, Jmlh Tahun Pendidikan, dan Pekerjaan diperkirakan menjadi fitur dengan kontribusi tertinggi terhadap prediksi kategori gaji, sejalan dengan temuan pada penelitian terdahulu menggunakan struktur dataset serupa yang menunjukkan capital gain dan occupation sebagai prediktor paling signifikan.”

Hipotesis ini didasarkan pada karakteristik algoritma Random Forest yang secara struktural dibangun dari kumpulan pohon keputusan yang dilatih pada subset data dan subset fitur secara acak (Breiman, 2001), sehingga penerapan pembobotan kelas pada level pembentukan pohon dapat memengaruhi kriteria pemilihan split secara langsung dan konsisten di seluruh ansambel, sebagaimana dijelaskan dalam kajian Chen, Liaw, dan Breiman (2004) mengenai penanganan data tidak seimbang menggunakan Random Forest. Sebagaimana akan dibahas pada BAB V, sebagian hipotesis ini terkonfirmasi namun sebagian lain perlu direvisi berdasarkan hasil aktual,

khususnya terkait peran Keuntungan Kapital yang ternyata tidak signifikan dugaan awal, dan performa XGBoost yang sedikit lebih unggul dibanding Random Forest pada beberapa metrik.

BAB III ANALISIS DATASET & REPRESENTASI DATA

3.1 Sumber dan Identitas Dataset

Atribut	Detail
Nama Berkas	train.csv
Jumlah Baris	35.994 baris data pekerja
Jumlah Kolom	13 kolom (12 fitur input + 1 target)
Struktur Dataset	Varian dari UCI Adult Census Income Dataset (Kohavi, 1996), dengan penamaan atribut dan kategori dialihbahasakan ke Bahasa Indonesia
Format Berkas	CSV (Comma-Separated Values) dengan delimiter titik koma
Sifat Data	Data tabular cross-sectional, satu baris mewakili satu pekerja

3.2 Struktur Data dan Tipe Fitur

Dataset berbentuk tabular dengan setiap baris mewakili satu individu pekerja. Berdasarkan hasil pemeriksaan langsung terhadap berkas train.csv, tidak ditemukan nilai kosong (NaN) secara eksplisit pada seluruh kolom, namun kolom Kelas Pekerja dan Pekerjaan mengandung nilai simbolik tanda tanya yang secara substansi merepresentasikan data tidak diketahui. Tipe data pada dataset ini mencakup kombinasi numerik kontinu, numerik diskret, dan kategorikal string, sehingga memerlukan strategi encoding dan scaling yang berbeda-beda untuk tiap kelompok fitur pada tahap praproses.

3.3 Tabel Deskripsi Fitur

Nama Fitur	Tipe Data	Kategori	Deskripsi
id	Numerik (int)	Non-Prediktif	Nomor identitas unik tiap baris data, tidak memiliki nilai prediktif
Umur	Numerik (int)	Input	Usia pekerja dalam tahun, rentang 17 hingga 90 tahun
Kelas Pekerja	Kategorikal (str)	Input	Status kepegawaian, misalnya Wiraswasta, Pemerintah Lokal, Pekerja Bebas Perusahaan

Nama Fitur	Tipe Data	Kategori	Deskripsi
Berat Akhir	Numerik (int)	Non-Prediktif	Bobot statistik sensus (final weight), tidak relevan untuk prediksi gaji individual
Pendidikan	Kategorikal (str)	Input	Jenjang pendidikan terakhir, misalnya SMA, D3, Sarjana, Master, Doktor
Jmlh Tahun Pendidikan	Numerik (int)	Input	Representasi numerik lama pendidikan formal dalam satuan tahun
Status Perkawinan	Kategorikal (str)	Input	Status pernikahan, misalnya Belum Pernah Menikah, Cerai, Menikah, Janda
Pekerjaan	Kategorikal (str)	Input	Jenis pekerjaan atau jabatan, misalnya Spesialis, Eksekutif Managerial, Sales
Jenis Kelamin	Biner (str)	Input	Jenis kelamin pekerja, Laki2 atau Perempuan
Keuntungan Kapital	Numerik (float)	Input	Nilai keuntungan dari investasi atau modal
Kerugian Capital	Numerik (float)	Input	Nilai kerugian dari investasi atau modal
Jam per Minggu	Numerik (float)	Input	Jumlah jam kerja dalam satu minggu
Gaji	Biner (str)	TARGET	Kategori pendapatan, $\leq 7jt$ atau $> 7jt$, label utama klasifikasi

3.4 Analisis Representasi Data


- **Feature vs Target**

Variabel target Gaji berbentuk dua kategori yaitu kurang dari sama dengan tujuh juta rupiah dan lebih dari tujuh juta rupiah. Untuk kebutuhan pemodelan klasifikasi, variabel ini dikonversi menjadi representasi numerik biner, yaitu 0 untuk kategori kurang dari sama dengan tujuh juta rupiah dan 1 untuk kategori lebih dari tujuh juta rupiah. Seluruh kolom lain, kecuali id dan Berat Akhir, berperan sebagai fitur input yang mendukung proses prediksi.

- **Class Imbalance**

Hasil eksplorasi distribusi variabel target menunjukkan ketidakseimbangan yang signifikan, yaitu 76,02 persen data (27.364 baris) berada pada kategori kurang dari sama

dengan tujuh juta rupiah dan hanya 23,98 persen (8.630 baris) pada kategori lebih dari tujuh juta rupiah, dengan rasio ketimpangan mencapai 3,17 banding 1, Sebagaimana ditunjukkan pada gambar berikut.




Gambar 3.1. Distribusi Kelas Target Gaji (Jumlah Data dan Proporsi Persentase)

Kondisi ini konsisten dengan karakteristik dataset sejenis pada penelitian pendapatan berbasis sensus, di mana kelompok berpendapatan tinggi secara alami selalu menjadi kelompok minoritas dalam populasi. Apabila tidak ditangani, ketimpangan ini berpotensi membuat model classifier cenderung memprediksi kelas mayoritas secara dominan, sehingga akurasi keseluruhan terlihat tinggi namun kemampuan mengenali kelas minoritas menjadi sangat rendah. Perlu dicatat bahwa angka 76,02 persen banding 23,98 persen di atas dihitung dari data mentah sebanyak 35.994 baris sebelum tahap pembersihan data. Setelah proses penghapusan kolom non-prediktif dan baris duplikat pada tahap preprocessing (dijelaskan pada BAB IV), proporsi kelas pada data bersih yang benar-benar digunakan untuk pelatihan model bergeser sedikit menjadi 73,82 persen banding 26,18 persen. Pergeseran ini wajar terjadi karena penghapusan duplikat tidak selalu menghapus baris pada kedua kelas secara proporsional, namun rasio ketimpangan pada kedua tahap tersebut tetap berada pada kisaran yang sama, yaitu sekitar 3 banding 1, sehingga kesimpulan mengenai perlunya penanganan class imbalance tidak berubah.

- **Hubungan Fitur dengan Target**

Analisis lebih lanjut terhadap hubungan tiap fitur dengan variabel target memperlihatkan beberapa pola yang konsisten dengan intuisi awal, sebagaimana divisualisasikan pada gambar berikut.



Gambar 3.2. Hubungan Fitur Demografis dan Latar Belakang Pekerjaan dengan Kelas Gaji

Pekerja pada kategori gaji lebih dari tujuh juta rupiah cenderung berusia lebih tua, bekerja dengan jam per minggu yang lebih panjang, dan memiliki lama pendidikan formal yang lebih tinggi dibandingkan kelompok kategori gaji kurang dari sama dengan tujuh juta rupiah. Dari sisi status perkawinan, kelompok yang berstatus menikah memiliki proporsi masuk kategori gaji tinggi yang jauh lebih besar dibandingkan kelompok lainnya, sementara dari sisi jenis kelamin, kelompok laki laki menunjukkan proporsi gaji tinggi yang secara jelas lebih besar dibanding perempuan.

- **Potensi Bias Demografis**

Sebagaimana umum ditemukan pada dataset sensus ketenagakerjaan, terdapat kemungkinan ketidakseimbangan representasi antar kelompok demografis, misalnya proporsi jenis kelamin atau kategori pekerjaan tertentu yang tidak merata. Kondisi ini perlu diwaspadai karena model yang dilatih pada data dengan representasi tidak merata berpotensi menghasilkan prediksi yang kurang akurat untuk kelompok yang jumlah datanya lebih sedikit, sehingga evaluasi model pada proyek ini akan turut mempertimbangkan performa per kelompok demografis, tidak hanya performa agregat.

3.5 Identifikasi Tantangan Dataset

- **Missing Class Imbalance**

Rasio 76 banding 24 antara kelas mayoritas dan minoritas pada variabel Gaji merupakan tantangan utama yang menjadi fokus proyek ini, sehingga memerlukan penanganan eksplisit melalui pendekatan class weighting.

- **Missing Values Tersembunyi**

Hasil pemeriksaan langsung menunjukkan kolom Kelas Pekerja mengandung 2.063 nilai tanda tanya (5,73 persen dari total data) dan kolom Pekerjaan mengandung 2.069 nilai tanda tanya (5,75 persen dari total data), yang secara substansi merepresentasikan data tidak diketahui, sehingga memerlukan strategi imputasi yang tepat agar tidak mengurangi jumlah data secara signifikan.

- **Noise pada Fitur Non-Prediktif**

Kolom id merupakan pengenal unik tanpa makna statistik, sedangkan kolom Berat Akhir merupakan bobot sampling sensus yang tidak merepresentasikan karakteristik individu, sehingga kedua kolom ini berpotensi menjadi sumber noise apabila tetap disertakan sebagai fitur.

- **Dimensi Kategorikal yang Cukup Tinggi**

Kolom Pekerjaan memiliki lebih dari sepuluh kategori unik, sehingga proses encoding perlu dirancang agar tidak menyebabkan dimensi fitur membengkak secara berlebihan setelah one-hot encoding.

- **Skewness pada Fitur Finansial**

Kolom Keuntungan Kapital dan Kerugian Capital didominasi nilai nol dengan sebagian kecil nilai ekstrem yang sangat besar, sehingga distribusinya sangat menceng dan berpotensi memengaruhi stabilitas model apabila tidak ditangani dengan tepat.

BAB IV PERANCANGAN PIPELINE

4.1 Data Preprocessing

1. Pembersihan Data Awal

Tahap pembersihan data diawali dengan menghapus kolom id dan Berat Akhir karena keduanya tidak memiliki nilai prediktif terhadap kategori gaji, mengingat id hanya berfungsi sebagai penanda baris sedangkan Berat Akhir merupakan bobot statistik sensus yang tidak merepresentasikan karakteristik individual pekerja. Setelah kedua kolom tersebut dihapus, ditemukan 6.735 baris yang menjadi identik satu sama lain pada sebelas kolom yang tersisa. Baris duplikat ini kemudian dihapus menggunakan `drop_duplicates()` untuk mencegah model mempelajari informasi yang sama secara berulang, sebab keberadaan data duplikat berpotensi membuat model terlalu percaya diri terhadap pola tertentu yang sebenarnya hanya muncul dari baris yang sama. Setelah proses ini, ukuran data berkurang menjadi 29.259 baris.

Selain itu, nilai tanda tanya yang ditemukan pada kolom Kelas Pekerja dan Pekerjaan digantikan dengan NaN menggunakan `df.replace('?', np.nan)`. Langkah ini penting dilakukan agar nilai yang hilang tersebut dapat dikenali secara eksplisit oleh sistem, alih alih dianggap sebagai kategori tersendiri yang justru bisa menyesatkan model saat proses pelatihan. Dengan mengubah simbol tersebut menjadi NaN, nilai yang hilang pada kedua kolom ini dapat ditangani secara terstruktur pada tahap imputasi selanjutnya di dalam pipeline preprocessing, sehingga kualitas data yang masuk ke model tetap terjaga.

2. Penanganan Outlier dengan IQR Clipping

Outlier pada empat fitur numerik ditangani menggunakan metode IQR clipping, yaitu memotong nilai yang berada di luar batas Q1 dikurangi 1,5 kali IQR dan Q3 ditambah 1,5 kali IQR. Pendekatan clipping dipilih dibanding penghapusan baris untuk menjaga jumlah data latih tetap maksimal. Hasil penerapannya adalah 129 nilai pada Umur dipotong ke batas atas 79 tahun, 2.985 nilai pada Keuntungan Kapital dan 1.652 nilai pada Kerugian Capital dipotong ke titik nol, serta 6.431 nilai pada Jam per Minggu dipotong ke rentang 26 hingga 58 jam.

Perlu digarisbawahi bahwa clipping pada Keuntungan Kapital dan Kerugian Capital bersifat cukup agresif karena memotong seluruh nilai non-nol ke titik nol, sebab secara statistik mayoritas nilai pada kedua kolom tersebut memang bernilai nol dengan sebagian kecil nilai ekstrem yang jauh di luar rentang IQR. Konsekuensinya, variasi asli kedua fitur tersebut menjadi hilang setelah tahap ini, sebuah hal yang perlu dipertimbangkan kembali pada iterasi eksperimen berikutnya, misalnya dengan menaikkan faktor pengali IQR khusus untuk fitur finansial agar tidak menghapus seluruh sinyal yang sebenarnya informatif.

3. Penanganan Missing Values

Nilai NaN yang telah teridentifikasi pada kolom Kelas Pekerja dan Pekerjaan kemudian diimputasi menggunakan modus, yaitu nilai kategori yang paling sering muncul, melalui SimpleImputer dengan strategy most_frequent. Proses imputasi ini diterapkan langsung di dalam pipeline encoding pada ColumnTransformer, sehingga fitting imputer hanya dilakukan pada data latih dan mencegah terjadinya kebocoran informasi dari data uji ke proses pelatihan model.

4. Encoding Fitur Kategorikal

Fitur kategorikal pada dataset ini ditangani dengan dua pendekatan encoding yang berbeda sesuai karakteristik masing masing fitur. One-Hot Encoding diterapkan pada fitur nominal yang tidak memiliki urutan alami, yaitu Kelas Pekerja, Status Perkawinan, Pekerjaan, dan Jenis Kelamin, menggunakan OneHotEncoder dengan parameter handle_unknown ignore dari scikit-learn. Sementara itu, Ordinal Encoding diterapkan khusus pada fitur Pendidikan karena fitur ini memiliki urutan jenjang yang jelas mulai dari SD hingga Doktor, menggunakan OrdinalEncoder dengan urutan kategori yang didefinisikan secara eksplisit sesuai jenjang pendidikan formal di Indonesia.

5. Feature Scalling

StandardScaler diterapkan pada fitur numerik kontinu, yaitu Umur, Jmlh Tahun Pendidikan, Keuntungan Kapital, Kerugian Capital, dan Jam per Minggu, untuk menyamakan skala antar fitur. Seluruh langkah imputasi, encoding, dan scaling di atas kemudian digabungkan dalam satu objek ColumnTransformer bernama preprocessor, sehingga transformasi yang identik dapat diterapkan secara konsisten baik pada data latih, data uji, maupun input baru saat inferensi di aplikasi Streamlit.

4.2 Feature Engineering

- Menghapus kolom id karena hanya berfungsi sebagai pengenalan baris dan tidak memiliki nilai prediktif terhadap kategori gaji.
- Menghapus kolom Berat Akhir karena merupakan bobot statistik sensus yang merepresentasikan tingkat representasi populasi, bukan karakteristik individual pekerja.
- Penanganan ketidakseimbangan kelas dilakukan melalui parameter `class_weight='balanced'` pada Random Forest dan Logistic Regression, serta parameter `scale_pos_weight` pada XGBoost, tanpa perlu melakukan oversampling atau undersampling secara terpisah.

4.3 Data Splitting Strategy

- Train Set: 80 persen dari data hasil pembersihan (23.407 baris dari total 29.259 baris).
- Test Set: 20 persen dari data hasil pembersihan (5.852 baris), digunakan khusus untuk evaluasi akhir dan tidak disentuh selama proses pelatihan maupun tuning.
- Pembagian data dilakukan menggunakan `train_test_split` dengan parameter `stratify=y` dan `random_state=42`, sehingga proporsi kelas tetap konsisten di angka 73,82 persen banding 26,18 persen pada data latih maupun data uji.
- Stratified 5-Fold Cross-Validation diterapkan pada data latih untuk proses tuning hyperparameter menggunakan `RandomizedSearchCV` dan validasi performa model utama, dengan tujuan menjaga proporsi kelas tetap konsisten pada setiap fold.

4.4 Pipeline Workflow End-to-End

No.	Tahapan	Detail Proses	Tools / Library
1	Input Data	Memuat train.csv (dengan fallback kagglehub), memeriksa dimensi dan tipe data	<code>pandas.read_csv()</code> , kagglehub
2	Exploratory Data Analysis	Visualisasi distribusi kelas, korelasi fitur, dan nilai unik tiap kategori	<code>pandas</code> , <code>matplotlib</code> , <code>seaborn</code>
3	Data Cleaning	Menghapus id dan Berat Akhir, menghapus 6.735 baris duplikat, IQR clipping, ganti '?' dengan NaN	<code>pandas</code> , <code>drop_duplicates()</code> , <code>numpy.clip()</code>

No.	Tahapan	Detail Proses	Tools / Library
4	Definisi Pipeline Preprocessing	ColumnTransformer berisi imputer, encoder, dan scaler per kelompok fitur	ColumnTransformer, Pipeline
5	Data Splitting	80% train, 20% test, Stratified split	train_test_split
6	Model Training (5 model)	Melatih RF Baseline, RF Weighted, RF Tuned, Logistic Regression, XGBoost	RandomForestClassifier, LogisticRegression, XGBClassifier
7	Hyperparameter Tuning	Mencari kombinasi n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features terbaik untuk RF	RandomizedSearchCV
8	Validasi	Stratified 5-Fold Cross Validation dan Learning Curve pada model utama	StratifiedKFold, learning_curve
9	Evaluasi Model	Menghitung akurasi, precision, recall, F1-score, ROC-AUC untuk kelima model	sklearn.metrics
10	Interpretasi Model	Feature importance bawaan, permutation importance, dan SHAP	sklearn.inspection, shap
11	Model Saving	Menyimpan seluruh model dan preprocessor	joblib.dump()
12	Deployment	Menampilkan dashboard EDA, form prediksi, evaluasi, dan dokumentasi dalam satu aplikasi	Streamlit, Streamlit Community Cloud

BAB V STRATEGI PEMODELAN & EKSPERIMEN

5.1 Algoritma Machine Learning yang Dipilih

Sesuai ketentuan tugas yang mensyaratkan implementasi minimal dua model berbeda, proyek ini membangun lima model dari tiga keluarga algoritma yang berbeda filosofi pembelajarannya: Random Forest (ensemble bagging, tiga varian), Logistic Regression (linear model), dan XGBoost (ensemble boosting).

Random Forest merupakan algoritma ensemble learning yang membangun sejumlah besar pohon keputusan secara independen, di mana setiap pohon dilatih pada subset data hasil bootstrap sampling dan subset fitur yang dipilih secara acak pada setiap split. Prediksi akhir untuk kasus klasifikasi ditentukan melalui mekanisme voting mayoritas dari seluruh pohon dalam ansambel. Karakteristik acak ganda ini membuat Random Forest memiliki varians yang lebih rendah dibandingkan pohon keputusan tunggal, sekaligus tetap mampu menangkap pola non-linear antar fitur.

Logistic Regression digunakan sebagai pembanding dari keluarga model linear. Berbeda dengan Random Forest yang non-linear, Logistic Regression mengasumsikan hubungan log-odds yang linear antara fitur dan target, sehingga cocok dijadikan pembanding untuk menguji apakah pola pada dataset ini lebih baik ditangkap secara linear atau non-linear. Logistic Regression tidak memiliki mekanisme `scale_pos_weight` seperti XGBoost, namun mendukung `class_weight='balanced'` yang setara secara konsep dengan Random Forest.

XGBoost mewakili keluarga ensemble boosting, di mana pohon-pohon dibangun secara berurutan dan setiap pohon baru berusaha memperbaiki kesalahan pohon sebelumnya, berbeda dengan Random Forest yang membangun pohon secara independen dan paralel. XGBoost tidak memiliki parameter `class_weight`, sehingga penanganan ketidakseimbangan kelas dilakukan melalui parameter `scale_pos_weight`, yaitu rasio jumlah sampel kelas negatif terhadap kelas positif pada data latih (dihitung sebesar 2,8197 pada data ini), sehingga kesalahan pada kelas minoritas diberi bobot lebih besar saat pembentukan setiap pohon boosting, mengikuti prinsip yang sama dengan class weighting pada Random Forest.

Mengapa Class Weighting atau Scale Pos Weight Krusial. Pada dataset dengan rasio kelas 76 banding 24, model yang secara naif selalu memprediksi kelas mayoritas akan tetap memperoleh akurasi sekitar 76 persen tanpa benar-benar mempelajari pola apa pun dari data. Oleh karena itu, ketiga keluarga algoritma pada proyek ini seluruhnya diterapkan dengan mekanisme penanganan imbalance yang setara secara konsep, agar perbandingan performa antar keluarga algoritma menjadi adil dan tidak bias oleh penanganan imbalance yang berbeda-beda.

5.2 Rancangan Eksperimen

1. Hyperparameter Tuning dengan RandomizedSearchCV

Tuning hyperparameter Random Forest dilakukan menggunakan RandomizedSearchCV dengan Stratified 3-Fold Cross Validation, scoring F1-score kelas minoritas, mencakup 8 kandidat kombinasi acak dari ruang pencarian `n_estimators` (100 sampai 500), `max_depth` (10, 15, 20, 30, None), `min_samples_split` (2, 5, 10), `min_samples_leaf` (1, 2, 5), dan `max_features` ('sqrt', 'log2'). RandomizedSearchCV dipilih dibanding GridSearchCV karena mampu menjelajahi ruang hyperparameter yang luas dengan jumlah percobaan yang jauh lebih sedikit, dan telah terbukti secara empiris memberikan hasil yang sebanding atau lebih baik dibanding grid search lengkap pada anggaran komputasi yang sama.

Kombinasi hyperparameter terbaik yang ditemukan adalah `n_estimators=200`, `max_depth=15`, `min_samples_split=10`, `min_samples_leaf=5`, dan `max_features='log2'`, dengan F1-score rata-rata cross validation sebesar 0,6695 selama pencarian.

2. Cross Validation dan Learning Curve

Stratified 5-Fold Cross-Validation diterapkan pada model utama untuk mengestimasi stabilitas performa secara lebih andal dibanding hanya mengandalkan satu kali pembagian data latih dan uji. Pada teknik ini, data latih dibagi menjadi lima bagian dengan proporsi kelas yang tetap terjaga pada setiap fold, kemudian model dilatih dan dievaluasi sebanyak lima kali dengan kombinasi fold yang berbeda pada tiap iterasi, sehingga hasil akhirnya berupa rata-rata performa yang tidak bergantung pada satu pembagian data tertentu saja. Selain itu, `learning_curve` digunakan untuk mendiagnosis kondisi overfitting atau underfitting pada berbagai ukuran data latih, dengan cara

membandingkan skor performa model pada data latih dan skor validasi silang seiring bertambahnya jumlah sampel yang digunakan untuk pelatihan. Kedua teknik ini saling melengkapi, cross validation memberi gambaran seberapa stabil performa model pada data yang berbeda-beda, sementara learning curve memberi gambaran apakah penambahan data lebih lanjut berpotensi meningkatkan performa atau model sudah mencapai titik jenuh, sebagaimana hasilnya dibahas lebih lanjut pada subbab 5.4.

5.3 Metrik Evaluasi


Metrik	Deskripsi	Interpretasi dalam Konteks Klasifikasi Gaji
Akurasi	Proporsi prediksi benar dari keseluruhan data	Kurang informatif secara tunggal karena data tidak seimbang, dapat menyesatkan apabila digunakan sebagai satu-satunya acuan
Precision	Proporsi prediksi kelas >7jt yang benar-benar tepat	Mengukur seberapa dapat dipercaya model ketika memprediksi seseorang berpendapatan tinggi
Recall	Proporsi kasus >7jt aktual yang berhasil terdeteksi oleh model	Mengukur seberapa baik model menangkap seluruh kelompok berpendapatan tinggi, krusial untuk kelas minoritas
F1-Score	Rata-rata harmonik antara precision dan recall	Metrik utama proyek ini karena menyeimbangkan kebutuhan presisi dan cakupan pada kelas minoritas
ROC-AUC	Area di bawah kurva ROC yang mengukur kemampuan model membedakan kedua kelas	Mengukur kualitas pemisahan kelas secara menyeluruh, tidak terpengaruh oleh pemilihan threshold tertentu

Akurasi tidak dijadikan metrik utama karena pada dataset dengan rasio kelas 76 banding 24, model yang selalu memprediksi kelas mayoritas akan tetap memperoleh akurasi sekitar 76 persen tanpa mempelajari pola apa pun. Oleh karena itu, keberhasilan proyek ini dinilai terutama dari recall dan F1-score kelas minoritas, konsisten dengan metrik kesuksesan yang telah ditetapkan pada BAB I.

5.4 Hasil Eksperimen: Perbandingan 5 Model


Kelima model dievaluasi pada data uji yang identik. Model pertama, Random Forest tanpa class weighting, menghasilkan akurasi 76,93 persen namun recall kelas >7jt hanya 50,20 persen. Model kedua, dengan class_weight='balanced', meningkatkan recall menjadi 53,39 persen. Model ketiga, RF Tuned (model utama), memberikan lonjakan performa paling signifikan di antara ketiga varian Random Forest, dengan recall 80,48 persen dan ROC-AUC 0,8732. Sebagai pembanding lintas keluarga algoritma, Logistic Regression menghasilkan recall 80,22 persen dengan ROC-AUC 0,8646, sementara XGBoost menghasilkan recall 81,40 persen dan F1-score 0,6667, keduanya sedikit di atas RF Tuned pada metrik tersebut, dengan ROC-AUC 0,8720 yang hampir setara.

Model	Akurasi	Precision (>7jt)	Recall (>7jt)	F1 (>7jt)	ROC-AUC
RF Baseline	0,7693	0,5671	0,5020	0,5325	0,8241
RF + Class Weighting	0,7722	0,5692	0,5339	0,5510	0,8240
RF Tuned (model utama)	0,7854	0,5630	0,8048	0,6625	0,8732
Logistic Regression	0,7758	0,5492	0,8022	0,6520	0,8646
XGBoost	0,7869	0,5645	0,8140	0,6667	0,8720




Gambar 5.1. Perbandingan Recall, F1-Score, dan ROC-AUC Lima Model pada Kelas >7jt

Temuan ini menunjukkan bahwa ketiga model yang telah ditangani ketidakseimbangan kelasnya (RF Tuned, Logistic Regression, XGBoost) berada pada level performa yang sebanding, jauh di atas RF Baseline dan RF + Weighting tanpa tuning. Ini mengonfirmasi bahwa class weighting atau scale_pos_weight adalah faktor yang jauh lebih menentukan performa pada kelas minoritas dibanding pemilihan keluarga algoritma itu sendiri, dan bahwa hyperparameter tuning tetap memberikan kontribusi tambahan yang berarti di dalam masing-masing keluarga algoritma.



Gambar 5.2. Perbandingan Confusion Matrix Model Baseline dan Model Utama (RF Tuned)

Confusion matrix RF Tuned dengan RF Baseline memperjelas dampak penanganan imbalance secara visual. Pada model baseline, sebagian besar kesalahan terjadi pada kuadran false negative, yaitu pekerja berpendapatan tinggi yang justru diprediksi berpendapatan rendah. Pada model utama, jumlah false negative berkurang signifikan, menandakan model menjadi jauh lebih peka terhadap kelompok minoritas yang menjadi fokus utama penelitian ini.



Gambar 5.3. Perbandingan Confusion Matrix Model Logistic Regression dan Model Utama (RF Tuned)

Perbandingan confusion matrix antara Logistic Regression dan model utama pada gambar di atas menunjukkan pola kesalahan yang sangat mirip antara kedua model. Logistic Regression mencatat 1.009 false positive dan 303 false negative, sementara RF Tuned mencatat 957 false positive dan 299 false negative dari total 5.852 data uji. Selisih pada kedua kuadran kesalahan ini tergolong kecil, hanya berbeda 52 kasus pada false positive dan 4 kasus pada false negative. Konsisten dengan tabel perbandingan pada subbab 5.4, recall kelas >7jt Logistic Regression tercatat 0,8022 dan RF Tuned 0,8048, sementara F1-score keduanya masing-masing 0,6522 dan 0,6625, dengan ROC-AUC 0,8646 berbanding 0,8732. Kemiripan pola kesalahan ini memperkuat kesimpulan pada subbab 5.7 bahwa ketiga model yang telah ditangani ketidakseimbangan kelasnya (RF Tuned, Logistic Regression, XGBoost) berada pada level performa yang sebanding, dan perbedaan di antara mereka lebih mencerminkan karakteristik masing-masing keluarga algoritma dibanding perbedaan kualitas model secara mendasar.

5.5 Validasi dan Diagnosis Model

Validasi silang Stratified 5-Fold pada model utama menghasilkan F1-score per fold sebesar 0,6671, 0,6733, 0,6795, 0,6631, dan 0,6667, dengan rata-rata 0,6699 dan standar deviasi 0,0058. ROC-AUC per fold sebesar 0,8760, 0,8779, 0,8818, 0,8728, dan 0,8785, dengan rata-rata 0,8774 dan standar deviasi 0,0030. Standar deviasi yang kecil pada kedua metrik menunjukkan bahwa performa model stabil dan tidak bergantung secara berlebihan pada satu pembagian data tertentu.


Analisis learning curve menunjukkan F1-score data latih menurun dari 0,7250 pada ukuran data latih terkecil (1.560 baris) menjadi 0,6984 pada ukuran data latih terbesar (15.604 baris), sementara F1-score cross validation naik dari 0,6611 menjadi 0,6699 pada rentang ukuran data yang sama. Gap tertinggi antara skor data latih dan cross validation tercatat sebesar 0,0639. Pola mengecilnya kesenjangan antara performa data latih dan validasi seiring bertambahnya data ini mengindikasikan model tidak mengalami overfitting yang berat.

- Overfitting akan ditandai apabila F1-score data latih jauh lebih tinggi dan gap-nya melebar seiring bertambahnya data. Pada kasus ini gap justru menyempit, sehingga indikasi overfitting berat tidak ditemukan.
- Underfitting akan ditandai apabila F1-score rendah di kedua set data. Pada kasus ini F1-score cross validation stabil di kisaran 0,66 hingga 0,67, cukup jauh di atas ambang batas underfitting (di bawah 0,50), sehingga kondisi ini juga tidak ditemukan.

5.6 Interpretasi Model

Interpretasi model dilakukan melalui tiga teknik yang saling melengkapi, mengikuti anjuran ketentuan tugas untuk menggunakan SHAP, LIME, atau permutation importance.


1. Feature Importance Bawaan (Mean Decrease in Impurity)



Gambar 5.4. Top 15 Feature Importance Bawaan Model Random Forest Utama

Status Perkawinan kategori Menikah memiliki skor tertinggi (0,2554), diikuti Jmlh Tahun Pendidikan (0,1259), Umur (0,1182), Status Perkawinan kategori Belum Pernah Menikah (0,1120), dan Pendidikan (0,1072).

2. Permutation Importance




Gambar 5.5. Permutation Importance terhadap F1-score Kelas >7jt

Permutation importance mengukur penurunan F1-score ketika nilai satu fitur diacak secara acak, sehingga mengukur kontribusi riil fitur terhadap performa prediksi, bukan sekadar seberapa sering fitur dipakai untuk split seperti pada feature importance bawaan. Hasilnya konsisten: Status Perkawinan tetap dominan (0,1762), diikuti Umur (0,0304) dan Jam per Minggu (0,0215). Menariknya, Keuntungan Kapital dan Kerugian Capital tercatat 0,0000, mengonfirmasi bahwa proses IQR clipping pada BAB IV memang menghilangkan variasi asli kedua fitur tersebut sehingga model tidak lagi menganggapnya penting.

3. SHAP (Shapley Additive exPlanations)

Feature importance bawaan dan permutation importance hanya memberikan interpretasi pada level global. SHAP (Lundberg & Lee, 2017) melengkapi keduanya dengan kemampuan menjelaskan kontribusi tiap fitur terhadap prediksi pada level individual, berdasarkan nilai Shapley dari teori permainan kooperatif.



Gambar 5.6. SHAP Summary Plot (Kontribusi Fitur terhadap Prediksi Kelas >7jt)

SHAP summary plot mengonfirmasi Status Perkawinan_Menikah sebagai fitur dengan rata-rata nilai $|\text{SHAP}|$ tertinggi (0,1389), jauh di atas fitur lain, diikuti Jmlh Tahun

Pendidikan (0,0585), Status Perkawinan_Belum Pernah Menikah (0,0562), Umur (0,0557), dan Pendidikan (0,0495). Konsistensi urutan fitur teratas di ketiga teknik interpretasi yang berbeda prinsip kerja ini memperkuat keyakinan bahwa dominasi status perkawinan bukan artefak dari satu metode pengukuran tertentu, melainkan pola yang benar-benar kuat dalam data.



Gambar 5.7. SHAP Force Plot: Penjelasan Prediksi untuk Satu Individu Contoh

Force plot di atas menunjukkan keunggulan utama SHAP dibanding dua teknik sebelumnya, yaitu kemampuan menjelaskan prediksi pada level individual. Untuk satu individu contoh pada data uji, model memprediksi probabilitas kelas >7jt sebesar 0,5349, dan force plot menunjukkan fitur mana yang mendorong prediksi ke arah tersebut (ditandai warna merah) dan fitur mana yang menahannya (ditandai warna biru). Kemampuan ini relevan apabila model digunakan untuk mendukung keputusan pada kasus per kasus, bukan sekadar analisis agregat.

5.7 Pemilihan Model Terbaik dan Justifikasi

Berdasarkan keseluruhan hasil eksperimen, Random Forest Tuned dengan Class Weighting ($n_estimators=200$, $max_depth=15$, $min_samples_split=10$, $min_samples_leaf=5$, $max_features='log2'$) dipilih sebagai model utama untuk deployment, dengan justifikasi sebagai berikut.

- Performa RF Tuned kompetitif dan berada pada level yang sebanding dengan XGBoost (selisih tidak lebih dari 0,01 pada seluruh metrik) dan Logistic Regression, sehingga bukan dipilih karena kebetulan unggul akibat minimnya pembandingan, melainkan telah teruji terhadap dua keluarga algoritma lain yang secara teoritis maupun praktis kompetitif.
- Stabilitas performa RF Tuned telah dikonfirmasi melalui validasi silang 5-fold dengan standar deviasi F1-score yang kecil (0,0058) dan ROC-AUC (0,0030).
- Random Forest lebih sederhana untuk dijelaskan ke pemangku kepentingan non-teknis dibandingkan XGBoost, dan tidak memerlukan tuning tambahan seperti $learning_rate$ yang lebih sensitif pada XGBoost.

- Tiga teknik interpretasi yang konsisten satu sama lain (feature importance, permutation importance, SHAP) memberikan keyakinan tinggi bahwa faktor penentu gaji yang diidentifikasi model bukan artefak dari satu metode pengukuran, melainkan pola yang benar-benar kuat dalam data, yaitu status perkawinan, usia, dan lama pendidikan formal.

Catatan mengenai keunggulan tipis XGBoost. Perlu diakui secara jujur bahwa pada tabel perbandingan di subbab 5.4, XGBoost mencatatkan angka accuracy, precision, recall, dan F1-score yang sedikit lebih tinggi dibanding RF Tuned, sementara ROC-AUC keduanya nyaris identik (0,8732 berbanding 0,8720). Selisih ini perlu dilihat dalam dua konteks. Pertama, seluruh selisih tersebut berada di bawah 0,01, sebuah margin yang secara praktis tidak signifikan mengingat ukuran data uji hanya 5.852 baris, sehingga berpotensi berubah apabila pembagian data latih dan uji diulang dengan random_state berbeda. Kedua, dan lebih penting, perbandingan ini belum sepenuhnya setara dari sisi upaya tuning, karena Random Forest melalui proses RandomizedSearchCV yang sistematis dengan delapan kombinasi hyperparameter, sementara XGBoost hanya diuji dengan parameter yang wajar tanpa pencarian ekstensif serupa. Dengan demikian, keunggulan tipis XGBoost pada eksperimen ini tidak dapat disimpulkan sebagai bukti bahwa XGBoost secara inheren lebih baik, melainkan lebih mencerminkan bahwa kedua algoritma berada pada level performa yang setara untuk kasus ini, dengan ruang peningkatan XGBoost yang kemungkinan belum tergali sepenuhnya, sebagaimana telah dicatat pada rekomendasi di BAB IX.

BAB VI DEPLOYMENT MODEL

6.1 Bentuk Deployment

Deployment model dirancang dalam bentuk satu aplikasi web interaktif menggunakan Streamlit, tanpa backend API terpisah. Seluruh logika pemuatan model, transformasi input, dan prediksi dijalankan langsung di dalam aplikasi Streamlit. Pendekatan single-app ini dipilih karena sesuai dengan ketentuan tugas yang meminta satu aplikasi web interaktif dengan lima komponen fungsional sekaligus, yaitu Dashboard EDA, Model Demo, Evaluasi Model, Interpretasi Hasil, dan Dokumentasi, sehingga tidak diperlukan komunikasi antar layanan melalui REST API. Struktur ini juga lebih sederhana untuk di-deploy ke Streamlit Community Cloud.

6.2 Model yang Digunakan

File	Isi	Keterangan
model/rf_tuned_main.pkl	Random Forest Tuned (class_weight='balanced')	Model utama yang dipakai aplikasi untuk prediksi, hasil RandomizedSearchCV dengan penanganan class imbalance
model/rf_baseline.pkl	Random Forest Baseline	Model pembandingan tanpa penanganan imbalance, untuk keperluan evaluasi komparatif
model/rf_weighted.pkl	Random Forest + Class Weighting (tanpa tuning)	Model pembandingan tahap menengah
model/logreg_pembandingan.pkl	Logistic Regression + Class Weighting	Model pembandingan dari keluarga linear
model/xgb_pembandingan.pkl	XGBoost + scale_pos_weight	Model pembandingan dari keluarga gradient boosting
model/preprocessor.pkl	Pipeline Preprocessing	ColumnTransformer (imputer, encoder, scaler) yang telah di-fit pada data latih
model/metrics.pkl	Artefak Evaluasi	Classification report, confusion matrix, feature importance, permutation importance, hasil SHAP, cross validation, dan learning curve dari kelima model, dihitung sekali saat training

Contoh kode inferensi langsung di dalam app.py:

```
import joblib

preprocessor = joblib.load('model/preprocessor.pkl')
model        = joblib.load('model/rf_tuned_main.pkl')

X_processed = preprocessor.transform(input_features)
prediction = model.predict(X_processed)
probability = model.predict_proba(X_processed)
```

6.3 Alur Input → Model → Output

Alur kerja aplikasi dimulai dari pengguna mengisi form pada tab Model Demo, kemudian aplikasi memuat preprocessor dan model dari berkas .pkl menggunakan cache resource Streamlit, mentransformasi input pengguna, menjalankan prediksi, lalu menampilkan hasilnya langsung di halaman yang sama.

Input (Diisi Pengguna Melalui Form pada Tab Model Demo)


Nama Field	Tippe Input	Contoh Nilai
umur	Number Input	35
kelas_pekerja	Dropdown	Wiraswasta, Pemerintah Lokal, dll.
pendidikan	Dropdown	Sarjana, Master, dll.
jmlh_tahun_pendidikan	Number Input	13
status_perkawinan	Dropdown	Menikah, Belum Pernah Menikah, dll.
pekerjaan	Dropdown	Spesialis, Eksekutif Managerial, dll.
jenis_kelamin	Dropdown	Laki2 atau Perempuan
keuntungan_kapital	Number Input	0
kerugian_capital	Number Input	0
jam_per_minggu	Number Input	40

Output (Hasil Prediksi yang Ditampilkan di Streamlit)

```
{
  "kategori_gaji_terprediksi": ">7jt",
  "probabilitas_kelas_1": 0.78,
  "probabilitas_kelas_0": 0.22,
```

```
"model_used": "Random Forest Tuned (class_weight=balanced)"
}
```

6.4 Diagram Alur Inference



Catatan: seluruh tahapan di atas berjalan dalam satu proses Streamlit yang sama (app.py), tanpa memerlukan pemanggilan REST API atau layanan backend terpisah, karena model dan preprocessor dimuat langsung ke memori aplikasi menggunakan cache resource Streamlit.

6.5 Struktur File Sistem

Path / File	Deskripsi
train_model.py	Script yang mereplikasi seluruh pipeline dari notebook, melatih kelima model, dan menyimpan seluruh artefak (.pkl)
model/*.pkl	Kelima model, preprocessor, dan artefak metrik (lihat tabel 6.2)
app.py	Aplikasi Streamlit tunggal berisi lima tab (Dashboard EDA, Model Demo, Evaluasi Model, Interpretasi Hasil, Dokumentasi)
requirements.txt	Daftar seluruh dependency Python yang dibutuhkan untuk deployment

Path / File	Deskripsi
README.md	Dokumentasi cara menjalankan proyek secara lokal

6.6 Arsitektur Sistem

Layer	Komponen & Teknologi
Presentation & Logic	Streamlit (Python), lima tab fungsional dalam satu app.py, memuat form input, visualisasi Plotly, dan logika prediksi sekaligus
Model Layer	RandomForestClassifier (scikit-learn) dengan class_weight='balanced', dimuat dari rf_tuned_main.pkl
Data & Artefak	train.csv sebagai sumber Dashboard EDA, metrics.pkl sebagai sumber tab Evaluasi Model dan Interpretasi Hasil
Hosting	Streamlit Community Cloud, terhubung langsung ke repository GitHub proyek

BAB VII DEPLOYMENT APLIKASI STREAMLIT

7.1 Ringkasan Aplikasi


Aplikasi diberi nama Salary Classifier Dashboard dan telah berhasil dikembangkan menggunakan Streamlit serta di-deploy secara publik melalui Streamlit Community Cloud, sehingga dapat diakses oleh siapa pun tanpa perlu instalasi apa pun di perangkat pengguna. Aplikasi ini dapat diakses melalui tautan berikut.

Tautan Aplikasi: <https://klasifikasigajipm.streamlit.app/>

Aplikasi terdiri dari lima tab fungsional sebagaimana disyaratkan pada ketentuan tugas, yaitu Dashboard EDA, Model Demo, Evaluasi Model, Interpretasi Hasil, dan Dokumentasi. Kelima tab tersebut dijelaskan pada subbab berikut, masing-masing dilengkapi tangkapan layar antarmuka sebagai bukti fungsionalitas deployment.

7.2 Tab 1: Dashboard EDA


Tab ini menampilkan visualisasi interaktif dari analisis data eksplorasi, meliputi bar chart dan pie chart distribusi kelas target Gaji, dropdown interaktif untuk memilih fitur (Umur, Jam per Minggu, Jmlh Tahun Pendidikan, Status Perkawinan, Jenis Kelamin, Pendidikan) yang menampilkan boxplot atau bar chart proporsi terhadap kelas Gaji, serta ringkasan statistik deskriptif dan jumlah missing value per kolom dalam bentuk tabel.



Gambar 7.1. Tampilan Tab Dashboard EDA pada Aplikasi yang Telah Di-deploy

7.3 Tab 2: Model Demo

Tab ini menyediakan form input data pekerja secara interaktif, dengan sepuluh field sesuai atribut input model (umur, kelas pekerja, pendidikan, jumlah tahun pendidikan, status perkawinan, pekerjaan, jenis kelamin, keuntungan kapital, kerugian kapital, dan jam per minggu). Opsi pada field kategorikal diambil otomatis dari nilai unik dataset, bukan di-hardcode. Setelah pengguna menekan tombol prediksi, aplikasi menampilkan hasil klasifikasi kategori gaji beserta probabilitasnya menggunakan model utama, Random Forest Tuned dengan Class Weighting.




The screenshot displays the 'Salary Classifier Dashboard' in a web browser. The dashboard has a dark theme and a sidebar on the left with navigation links: 'Salary Predictor & EDA Portal', 'Ujian Akhir Semester', 'Pembelajaran mesin', and 'Developer'. The main area is titled 'Salary Classifier Dashboard' and 'Prediksi dan Analisis Kategori Gaji Pekerja berbasis Machine Learning (Random Forest dengan Pendekatan Class Weighting)'. It features a 'Demo Prediksi Kategori Gaji' section with a form for inputting worker data. The form includes fields for 'Umur' (35), 'Kelas Pekerja' (Pekerja Bebas Bukan Perusahaan), 'Pendidikan' (10th), 'Jmlh Tahun Pendidikan' (12), 'Status Perkawinan' (Belum Pernah Menikah), 'Pekerjaan' (Asisten Rumah Tonggo), 'Jenis Kelamin' (Laki2), 'Keuntungan Kapital' (0), 'Kerugian Capital' (0), and 'Jam per Minggu' (40). A 'Prediksi' button is located at the bottom of the form. The footer of the dashboard shows the copyright information: '© KAYLA VERDA - A11.2024.15689'.

Gambar 7.2. Tampilan Tab Model Demo pada Aplikasi yang Telah Di-deploy

7.4 Tab 3: Evaluasi Model

Tab ini menampilkan tabel perbandingan performa model, confusion matrix, hasil cross validation, dan learning curve, sebagaimana telah dibahas secara rinci pada BAB V. Untuk menjaga tampilan tetap fokus dan mudah dipahami oleh pengguna non-teknis, perbandingan utama yang ditonjolkan pada tab ini adalah antara Random Forest (model utama) dan Logistic Regression sebagai wakil model dari keluarga algoritma yang berbeda, sementara data lengkap kelima model tetap tersimpan pada metrics.pkl dan didokumentasikan penuh pada laporan ini serta notebook eksperimen.



Gambar 7.3. Tampilan Tab Evaluasi Model pada Aplikasi yang Telah Di-deploy


Tab ini juga menampilkan kotak validasi otomatis terhadap metrik kesuksesan proyek yang telah ditetapkan pada BAB I, yaitu recall kelas >7jt di atas 0,75 dan ROC-AUC di atas 0,85. Sebagaimana terlihat pada gambar di atas, model utama (RF Tuned) mencapai recall 0,8048 dan ROC-AUC 0,8732, sehingga kedua target tersebut dinyatakan tercapai langsung di dalam aplikasi tanpa perlu verifikasi manual.




Gambar 7.4. Tampilan Tab Evaluasi Model 2 pada Aplikasi yang Telah Di-deploy

7.5 Tab 4: Interpretasi Hasil

Tab ini menampilkan grafik feature importance beserta penjelasan naratif mengenai fitur paling berpengaruh dan insight bisnis yang dapat diambil dari model, termasuk catatan mengenai temuan Keuntungan Kapital dan Kerugian Capital yang tidak masuk fitur penting akibat proses IQR clipping.




Gambar 7.5. Tampilan Tab Interpretasi Hasil pada Aplikasi yang Telah Di-deploy



Gambar 7.6. Tampilan Tab Interpretasi Hasil 2 pada Aplikasi yang Telah Di-deploy

7.6 Tab 5: Dokumentasi

Tab ini berisi penjelasan mengenai sumber dan struktur dataset, ringkasan metodologi yang digunakan, serta panduan singkat cara menggunakan tiap tab pada aplikasi ini, sehingga pengguna non-teknis sekalipun dapat memahami cara kerja dan konteks aplikasi tanpa perlu membaca kode program secara langsung.



Salary Classifier Dashboard
Prediksi dan Analisis Kategori Gaji Pekerja berbasis Machine Learning (Random Forest dengan Pendekatan Class Weighting)

Dashboard EDA Model Demo Evaluasi Model Interpretasi Hasil **Dokumentasi**

Dokumentasi Proyek

1. Penjelasan Dataset

Dataset yang digunakan dalam proyek ini diadaptasi dari UCI Adult Census Income Dataset (Kohavi, 1996) yang memuat profil sosio-demografis dan pekerjaan individu untuk memprediksi tingkat pendapatan. Dataset mentah (`datasetPekerja.csv`) memiliki total baris 35.994 baris dan 13 kolom (fitur).

Distribusi Target:

- Kelas ≤ 7 (Gaji Rendah): 27.364 baris (~76%)
- Kelas > 7 (Gaji Tinggi): 8.630 baris (~24%)
- Rasio Imbalance: Sekitar 3.17:1, menunjukkan ketidakseimbangan kelas yang signifikan.

Nama Fitur	Tipe	Deskripsi	Nama Fitur
id	Numerik	Indeks / Nomor Urut data (Dihapus dari Pemodelan)	
Umur	Numerik	Usia Pekerja (di-clipping dalam batas IQR [-1 : 79] tahun)	
Kelas Pekerja	Kategorik	Sektor ketenagakerjaan (Wiraswasta, Pekerja Negara, dll.)	
Pendidikan	Kategorik (Ordinal)	Tingkat pendidikan tertinggi (SD hingga Doktor)	
Jmlh Tahun Pendidikan	Numerik	Lama durasi menempuh pendidikan dalam tahun	
Status Perkawinan	Kategorik	Status perkawinan pekerja (Menikah, Belum Menikah, Cerai, dll.)	
Pekerjaan	Kategorik	Sektor pekerjaan spesifik pekerja (Manajerial, Spesialis, dll.)	
	Kategorik	Jenis kelamin pekerja (Laki-laki, Perempuan)	Jenis Kelamin
Keuntungan Kapital	Numerik	Keuntungan dari investasi keuangan (di-clipping IQR ke [0.0 - 0.0])	

© KAYLA VERDA - A11.2024.15689 Manage app

Gambar 7.7. Tampilan Tab Dokumentasi pada Aplikasi yang Telah Di-deploy

BAB VIII KESIMPULAN DAN REKOMENDASI

8.1 Kesimpulan

Berdasarkan seluruh tahapan yang telah dilakukan, dari analisis data hingga deployment aplikasi, dapat disimpulkan beberapa hal berikut.

- Dataset train.csv terbukti mengandung ketidakseimbangan kelas yang signifikan pada variabel Gaji, dengan rasio sekitar 3 banding 1, baik pada data mentah maupun data yang telah dibersihkan.
- Penerapan class weighting atau scale_pos_weight terbukti krusial di ketiga keluarga algoritma yang diuji. Recall kelas minoritas meningkat dari 50,20 persen pada RF Baseline menjadi 80,48 persen pada RF Tuned, 80,22 persen pada Logistic Regression, dan 81,40 persen pada XGBoost.
- Random Forest Tuned, Logistic Regression, dan XGBoost menunjukkan performa yang sebanding satu sama lain setelah sama-sama menerapkan penanganan imbalance, dengan selisih tidak lebih dari 0,01 pada seluruh metrik utama, mengonfirmasi bahwa penanganan class imbalance jauh lebih menentukan performa dibanding pemilihan keluarga algoritma.
- Tiga teknik interpretasi yang berbeda prinsip kerja (feature importance bawaan, permutation importance, dan SHAP) secara konsisten mengidentifikasi Status Perkawinan kategori Menikah, Umur, dan Jmlh Tahun Pendidikan sebagai faktor paling berpengaruh terhadap kategori gaji, sementara Keuntungan Kapital dan Kerugian Capital yang semula diperkirakan penting justru tidak berpengaruh signifikan akibat proses IQR clipping yang menghilangkan variasi aslinya.
- Model utama berhasil diimplementasikan ke dalam aplikasi web interaktif berbasis Streamlit yang telah di-deploy secara publik dengan lima tab fungsional, memungkinkan pengguna non-teknis melakukan eksplorasi data, mencoba prediksi, meninjau evaluasi model, dan memahami interpretasi hasil tanpa perlu membaca kode program.

8.2 Rekomendasi

Beberapa rekomendasi berikut diajukan untuk pengembangan lebih lanjut.

- Meninjau ulang ambang batas IQR clipping pada fitur Keuntungan Kapital dan Kerugian Capital, misalnya menggunakan pengali IQR yang lebih besar atau

transformasi logaritmik, agar sinyal yang secara teoritis relevan pada kedua fitur tersebut tidak hilang akibat proses pembersihan data yang terlalu agresif.

- Melakukan tuning hyperparameter yang lebih sistematis pada XGBoost dan Logistic Regression, mengingat pada proyek ini kedua model tersebut hanya diuji dengan parameter yang wajar tanpa pencarian ekstensif seperti pada Random Forest, sehingga performa keduanya berpotensi masih dapat ditingkatkan.
- Mempertimbangkan teknik penanganan imbalance tambahan seperti SMOTE (Chawla et al., 2002) sebagai pembanding terhadap class weighting yang telah diterapkan, untuk melihat apakah kombinasi keduanya dapat memberikan performa yang lebih baik lagi.
- Menambahkan fitur interaksi antar variabel, seperti kombinasi Jmlh Tahun Pendidikan dan Jam per Minggu, pada iterasi eksperimen berikutnya untuk melihat apakah performa model dapat ditingkatkan lebih jauh.
- Melengkapi aplikasi Streamlit dengan opsi bagi pengguna untuk memilih model mana yang ingin digunakan untuk prediksi (RF Tuned, Logistic Regression, atau XGBoost), sehingga pengguna dapat membandingkan hasil prediksi antar model secara langsung di dalam aplikasi.

DAFTAR PUSTAKA

- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13(10), 281-305.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
- Chen, C., Liaw, A., & Breiman, L. (2004). Using random forest to learn imbalanced data. Technical Report 666, Department of Statistics, University of California, Berkeley.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263-1284.
- Kohavi, R. (1996). Scaling up the accuracy of Naive-Bayes classifiers: A decision-tree hybrid. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 202-207.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of IJCAI*, 14(2), 1137-1145.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8, 25.